

LE PROJET EN UNE PHRASE

Un assistant qui, à partir d'une question en français, **retrouve** les articles pertinents du Code du travail, **génère** une réponse fondée *uniquement* sur eux, **cite** les numéros d'articles, et **s'abstient** si la réponse n'y est pas. Le tout **en local** : la question du citoyen ne quitte pas le pays.

LES CHIFFRES À CONNAÎTRE

588	articles extraits et découpés (mon parser)
589	articles au total dans la Loi 65-99
2011	date de consolidation de la version FR
2021	version AR — diffère sur 2 articles : 32 et 256
8192	tokens de contexte de BGE-M3 → aucun article tronqué
30-50	questions du jeu d'évaluation de référence

DÉFINITIONS EXPRESS

- RAG** — *Retrieval-Augmented Generation*. On **retrouve** le texte pertinent, puis on demande au modèle de répondre **en s'appuyant seulement dessus**. Le savoir reste dans le corpus, pas dans les poids du modèle.
- Embedding** — Un vecteur de nombres qui représente le **sens** d'un texte. Deux textes de sens proche donnent deux vecteurs proches — même s'ils n'ont aucun mot en commun.
- Similarité cosinus** — On mesure l'**angle** entre deux vecteurs, pas leur longueur. Angle petit = sens proche. C'est ce qui classe les résultats.
- Base vectorielle** — Stocke les vecteurs et retrouve très vite les **plus proches voisins** d'une question. Ici : **Chroma**.
- Chunk** — Le morceau de texte indexé. Chez moi **1 chunk = 1 article** — car c'est l'unité que le droit cite naturellement.
- BM25** — Recherche **lexicale** (mots exacts), pas sémantique. Excellente sur « article 152 », « Loi 65-99 » — là où les embeddings sont faibles.
- Recherche hybride / RRF** — On lance dense et BM25, puis on **fusionne** les deux classements (*reciprocal rank fusion*).
- Reranker** — Un *cross-encodeur* qui lit le couple (question, article) **ensemble** → plus précis. On récupère 10 candidats, on n'en garde que 3.
- Ancrage (grounding)** — Contraindre le modèle à ne répondre qu'à partir des articles fournis dans le prompt.
- Hallucination** — Le modèle invente une réponse plausible mais fausse. C'est le risque n°1 d'un assistant juridique.
- Abstention** — Dire « je n'ai pas l'information » plutôt qu'inventer. **Ce n'est pas un échec, c'est le comportement correct**.
- Quantification** — Compresser les poids du modèle (ex. Q4) pour le faire tenir en mémoire. ~5 Go pour un 7B.

LA STACK — ET UNE RAISON CHACUNE

Extraction	PyMuPDF — rapide, accents fiables, contrôle total du découpage
Embeddings	BGE-M3 — local, FR+AR, contexte long 8192 tokens
Base vect.	Chroma — embarquée, zéro serveur, filtre par métadonnées
Lexical	BM25 (rank_bm25) — fusionné au dense par RRF
Reranker	bge-reranker-v2-m3 — optionnel, à <i>mesurer</i>
LLM	Qwen3 8B ou Mistral 7B, servi par Ollama
Framework	Aucun — la boucle RAG fait ~150 lignes, je la maîtrise
Corpus	JSONL — 1 chunk/ligne, lisible, diff-able sous Git
Éval	Scripts + pandas + correction manuelle

LES 2 FILTRES QUI JUSTIFIENT TOUT

1. **Souveraineté** → **tout en local**. Ce seul critère élimine *toutes* les options par API : embeddings OpenAI/Cohere, GPT-4, Claude, Gemini. La plupart des « pourquoi pas X ? » se résument à : *X est une API*.
2. **Corpus borné (~milliers de chunks) + 8 semaines** → **optimiser la maîtrise, pas la performance**. À cette taille, **toutes** les bases vectorielles sont instantanées : la vitesse n'est jamais le critère.

SI ON ME DEMANDE...

- Pourquoi pas GPT-4 / Claude ?**
Souveraineté. La question d'un citoyen sur son droit du travail ne doit pas quitter le pays. Le prix de ce choix : un modèle local plus faible — ce qui **augmente l'exigence sur l'ancrage**, et c'est en soi un résultat à analyser.
- Pourquoi Chroma et pas FAISS / pgvector ?**
À quelques milliers de chunks, la performance est hors sujet. J'ai optimisé le confort de développement : Chroma est embarquée, persiste toute seule, filtre par métadonnées. **pgvector serait un choix tout à fait valable** vu mon fond SQL — j'ai échangé la familiarité contre zéro ops.
- Pourquoi BGE-M3 ?**
Local (donc souverain), couvre FR et AR, et son contexte de 8192 tokens évite de tronquer les articles longs. **multilingual-e5 est une alternative légitime**, plus légère — l'écart est mince.
- Pourquoi aucun framework (LangChain / LlamaIndex) ?**
Pour un corpus borné, la boucle fait ~150 lignes. La coder moi-même = comprendre chaque étape et pouvoir la déboguer. **C'est l'appel le plus discutable** : si acquérir LangChain est un objectif de formation, la décision change.
- L'arabe fait foi juridiquement, non ?**
Oui — le texte arabe prévaut, le français est une traduction officielle. Je construis sur le FR (extraction propre, évaluable), je **patche les 2 articles divergents** (32, 256) et je **déclare la limite** dans le rapport. L'arabe passera par une couche de traduction, pas par un second moteur.
- Comment il évite d'inventer ?**
Trois verrous : (1) un **seuil d'abstention avant le LLM** — indépendant du modèle ; (2) un prompt d'ancrage strict + température basse ; (3) une **vérification a posteriori** que chaque article cité figure bien dans le contexte fourni.
- Comment tu l'évalues ?**
Recall@k et MRR **automatisés** (les articles de référence sont connus). Correction **manuelle** de la justesse et des citations sur 30-50 questions — plus honnête qu'un juge LLM. Plus une analyse d'erreurs : *recherche vs génération vs abstention*.

OÙ J'EN SUIS

Mission 1, en avance. Extraction PDF faite (encodage UTF-8 corrigé), parser écrit à la main, **588 articles** proprement séparés, préface et table des matières isolées. **Ensuite** : nettoyage du texte, métadonnées de hiérarchie (livre / titre / chapitre), sérialisation JSONL — puis le premier pipeline RAG bout-en-bout.

À DIRE SI JE SÈCHE

- « Ça, je ne l'ai pas encore mesuré — c'est prévu en semaine 5/6. Ce que je peux dire aujourd'hui, c'est... »
- Ne jamais affirmer un chiffre de performance non mesuré. **Un « je ne sais pas encore, voici quand je le saurai » vaut mieux qu'une estimation inventée** — c'est exactement le principe d'abstention que je code dans le système.

Formule d'avertissement (à la fin de chaque réponse du système) :
« Réponse fournie à titre informatif ; pour une situation particulière, consultez un professionnel. »