

Latence — répartition du temps de réponse (secondes)



L'abstention pré-LLM ne paie que la recherche : le modèle n'est jamais appelé.